경력기술서

전대홍

Redshift → Databricks 메달리온 레이크하우스 전환

CDC 기반 준실시간 레이크하우스 구축 · 운영 PFCT · 2026.02 - 현재

1. 배경 및 목표

- 운영 DB를 DMS로 Redshift에 직접 복제하는 구조로, 적재 작업이 Redshift 실행 시간의 58% ~ 최대 99.8%를 차지해 조회 성능 저하. 적재 · 조회 컴퓨트 분리 필요
- 데이터를 다시 만들려면 운영 DB를 재조회해야 하고, 변경 이력 · 삭제 기록 · 64KB 초과 값 보존 불가
- 약 1,600개 테이블을 준실시간으로 적재하되, 일 DBU 비용 상한 안에서 운영

2. 기술 스택 및 환경

- Python, Spark, Databricks, Delta Lake, AWS DMS, S3, Aurora MySQL, Redshift, Airflow
- DMS CDC 태스크 30개 이상의 AWS 클라우드 환경
- 약 1,600개 테이블, 수십TB 규모 데이터

3. 주요 업무 및 상세 역할

- Tech Proposal 작성 → PoC → 설계 및 구축까지 주도
- 메달리온 계층별 S3 버킷 · Unity Catalog 구조와 권한 · 라이프사이클 정책 설계
- Aurora 스냅샷 S3 Export 기반 초기 풀로드 설계 · 수행
- DMS CDC → S3 Landing → Delta Lake Bronze 준실시간 적재 아키텍처 설계 · 개발
- Fan-out 스트리밍 Job 설계 및 MERGE 성능 최적화
- Landing ↔ Bronze 전수 정합성 검증(DQ) 체계 구현

4. 비즈니스 가치 및 기술적 성과

- 메달리온 계층별 S3 버킷 · Unity Catalog 구조를 설계하고 계층별 권한 · 라이프사이클 정책을 적용하여, 데이터 접근 통제와 스토리지 관리 기준 확립
- Read Replica에서 풀로드 시 조회 성능 저하와 장시간 적재가 발생해, Aurora 스냅샷을 S3로 Export(Parquet)하는 방식으로 전환하여 운영 DB · 복제본 부하 없이 **수십TB 초기 적재**
- DMS CDC → S3 Landing → Delta Lake Bronze 준실시간 적재를 구축하여, **약 1,600개 테이블**을 **End-to-End Latency p99 30초**로 적재
- 테이블별 스트림 구조(DLT)를 스키마당 스트림 하나가 테이블별로 분배 · MERGE하는 Fan-out Job으로 재설계하여, **CPU 75% · 메모리 66% · Compute 비용 39% 절감**
- Execution Plan 분석으로 NULL 허용 머지 키(<=>)가 Data Skipping을 막아 전체 스캔하는 원인을 찾고, 키 범위 조건 추가와 <=> 제한 적용으로 **Merge 시간 73% 단축**
- 약 1,600개 테이블 전수 정합성 검증(DQ)을 자동화하여 **적재 누락 31만 건 · CDC 순서 오류 15만 건**을 탐지하고, 멱등한 조건부 MERGE로 복구하여 **최종 누락 0건** 달성
- Redshift 감사 로그와 Airflow DAG 분석으로 테이블을 실시간 · 6시간 · 일 배치로 등급화하고, 등급별 Job 클러스터와 인스턴스 타입을 최적화하여 **일 운영 비용 DBU $100 이내** 달성

데이터 분석 전용 온톨로지 · 시맨틱 레이어 구축

분석용 Data Mart 및 지표 표준화 질의 엔진 개발 PFCT · 2026.03 - 2026.11

1. 배경 및 목표

- 데이터 분석가들이 의미가 겹치는 테이블과 중복 컬럼 때문에 어떤 테이블을 써야 할지 판단하기 어려워, 분석용 데이터 정리와 질의 체계 개선을 요청
- 사내 공용 에이전트의 분석용 온톨로지가 원천 테이블을 그대로 매핑해, 같은 질문에도 다른 답 발생(정답률 17%, 일관성 30%)
- 금융 데이터 특성상 정확성 · 일관성이 필수이며, 흩어진 지표 정의를 한 곳으로 모을 필요

2. 기술 스택 및 환경

- Python, SQL, OWL/RDF(Turtle), Redshift, LLM(Claude), AWS EKS, ECR, S3
- 사내 DW의 대출 · 투자 · 신용 도메인 테이블 환경

3. 주요 업무 및 상세 역할

- Redshift 대출 도메인 테이블 약 250개의 중복 · 구조 분석 및 분석용 Data Mart 설계 · 구축
- OWL 기반 데이터 · 지표 정의 계층 설계
- LLM 질의 의도 추출 · 실행 전 검증 · SQL 컴파일러 구조의 질의 엔진 설계 · 개발
- 정답지 기반 정확도 · 일관성 측정 하네스 및 테스트 체계 개발

4. 비즈니스 가치 및 기술적 성과

- Redshift에 파편화된 **약 250개 대출 도메인 테이블**의 중복 테이블 · 컬럼과 구조를 분석하고, 업무 흐름 기준으로 통합 · 재구성해 기준 테이블이 하나인 분석용 Data Mart 구축
- 단계별 출력을 비교하는 측정 하네스로 불일치 원인을 분리하고, LLM은 질의 의도만 구조화해 추출하고 코드가 SQL을 생성하는 구조로 재설계
- 현업 질문 61문항 × 20회 반복 테스트에서 기존 대비 **정답률 17% → 98%**, 동일 질문 응답 **일관성 30% → 98%** 개선
- 동일 테스트 기준 **응답 시간 91% 단축**(416분 → 38분), **LLM 토큰 사용량 87% 절감**(134.8M → 17.2M)

Hadoop Ecosystem 기반 플랫폼 성능 최적화 및 고도화

NH 금융 빅데이터 개인신용정보 파기 프로세스 성능 개선 (주)디딤365 · 2025.04 - 2025.08

1. 배경 및 목표

- 매년 데이터가 꾸준히 늘면서 기존 Hive 기반 데이터 처리 애플리케이션의 성능 저하. 개선 필요
- 금융감독원 제출을 위한 데이터 처리 결과 자동화 필요
- 운영 중 발생하는 플랫폼(애플리케이션)의 주요 이슈 해결

2. 기술 스택 및 환경

- Java, Scala, Spring Boot, Spark, Hadoop, YARN, Hive, Zookeeper, Oozie, MySQL, Impala, Hue
- 30대 이상 규모의 Hadoop 클러스터 환경
- 테이블당 수십TB ~ 수백TB 이상의 데이터 환경

3. 주요 업무 및 상세 역할

- 성능 향상을 위한 프로세스 재설계, Spark · Hive 데이터 처리 애플리케이션 개발
- 데이터 처리 프로세스 리팩토링을 통해 집계 로직을 자동화하여 운영 효율성 향상
- 수백TB의 데이터를 활용하여 성능 및 안정성 검증
- TCP Leak, Memory OOM 등 운영 환경에서 발생하는 플랫폼(애플리케이션)의 주요 이슈 해결

4. 비즈니스 가치 및 기술적 성과

- 하나의 Spark 애플리케이션 안에서 파티션 단위 Job을 멀티 스레드로 동시 제출해 유휴 Executor 슬롯을 채우고, Spark UI로 Task 분포 · GC를 검증하여 약 1,100개 파기 작업의 **CPU 코어 사용률 20~30% → 80%, 처리 시간 70% 단축**
- 한 번에 돌던 백업 · 파기 작업을 단계별로 나누고, 실패하면 **실패한 파티션부터 재실행**하도록 개선. 같은 파티션을 다시 돌려도 결과가 같도록 덮어쓰기(INSERT OVERWRITE) 방식으로 설계
- 파기 건수를 집계하려고 매번 4억 행 백업 테이블을 Join하고 사람이 다시 집계하던 과정을, 백업 시점에 파기 대상을 미리 표시하는 방식으로 바꿔 **전체 워크플로우 시간 80% 단축** 및 금융감독원 제출 집계 자동화
- Hive 통계가 없어 작은 기준 테이블도 큰 테이블로 판단되어 Sort-Merge Join으로 처리되던 것을 Broadcast Join으로 바로잡아, 같은 자원에서 **처리량 20% 향상**
- Spark 쓰기 시 셔플 파티션 수만큼 파일이 쪼개져 쌓이던 Small File 문제를 데이터 크기에 맞춘 coalesce로 병합해, **NameNode 메타데이터 · 후속 조회 부하 감소**
- JVM Heap Dump 분석으로 Bean Lifecycle · Task 객체(Map)의 메모리 누수를, 예외 처리의 finally 누락으로 생긴 TCP Connection 누수를 찾아 제거하여 **월 장애 시간 90% 이상 감소, 가용성 99.9%** SLA 충족
- 프로젝트 성과로 고객사에 기술 역량을 인정받아 **후속 프로젝트 계약 유치**, 수억 원 규모 매출에 기여

Spark · Iceberg 기반 대규모 데이터 파이프라인 플랫폼 설계 · 개발

Didim-DP Batch Cloud Solution 개발 (주)디딤365 · 2024.07 - 2025.03

1. 배경 및 목표

- 기존 Hadoop 에코시스템에 종속된 아키텍처에서 벗어나, 유연하게 동작하는 데이터 처리 플랫폼 필요
- DB, Cloud Storage, NAS, Hive 등 다양한 엔드포인트에서 데이터를 효율적으로 추출 · 적재하는 구조 설계 및 구현
- 고정된 수집-변환-적재(ETL) 구조에서 벗어나, DAG 기반 파이프라인으로 분기 · 이벤트 · 병렬 · 조건별 처리 등 다양한 데이터 흐름 지원

2. 기술 스택 및 환경

- Java, Scala, Spring Boot, Spark, Iceberg, DuckDB, Zookeeper, MinIO, AWS S3, AWS Aurora, Hive, MySQL, Oracle, GitLab Runner
- 온프레미스 서버 7대 환경
- 일 평균 25억 건 데이터 처리 환경

3. 주요 업무 및 상세 역할

- Spark · Iceberg 기반 분산 데이터 처리 체계 및 플랫폼 아키텍처 설계 · 개발
- Module H/A 구성 및 Failover 체계 설계 · 구현
- Iceberg Expired Snapshot · Orphan File 관리 체계 구현
- Spark Standalone용 DB Lock 기반 자원 스케줄러 개발

4. 비즈니스 가치 및 기술적 성과

- Spark · Iceberg 기반 데이터 처리 체계를 신규 아키텍처로 설계 · 구현하여, 기존 Hadoop 기반 ETL 대비 **처리 시간 40% 단축** 및 HDFS 종속성 제거로 S3 · Glue 등 클라우드 확장성 확보
- Module H/A 구성 및 Failover 체계 구현으로 장애 시 대기 노드로 자동 전환되도록 하여 **장애 자동 복구율 95% 이상** 달성
- Iceberg Expired Snapshot 및 Orphan File 관리를 자동화하여 **스토리지 사용량 30% 이상 절감**, 장기 운영 시 메타데이터 누적으로 인한 성능 저하 예방
- Spark Standalone에 DB Lock 기반 자원 스케줄러를 구축해 Core · Memory 할당량과 SLA Queue별 작업 제출을 제어하고, Driver 병목에 따른 데드락을 방지해 **일 평균 800개 이상 배치 작업** 안정 처리
- **일 평균 25억 건** 이상의 대용량 데이터 처리 환경에서 성능 · 안정성을 검증하고, 금융권 고객사 프로젝트에 납품 · 운영