전대홍

Data Engineer

daehong770@gmail.com | GitHub | Blog | LinkedIn

Introduce.

Spark · Iceberg 기반 데이터 플랫폼과 Hadoop 에코시스템 기반 ETL 플랫폼을 설계 · 개발하고 성능을 최적화하며, 운영 환경에서 **일 평균 25억 건, 수백TB 규모**의 데이터를 처리했습니다.

Redshift DW를 Databricks 메달리온 아키텍처로 전환하며 **약 1,600개 테이블 · 20TB 이상**의 데이터를 **적재 누락 0건**으로 이관했습니다.

문제가 생기면 먼저 측정해서 원인을 찾고, 기술 제안과 PoC로 검증한 뒤 구조를 바꾸는 방식으로 일합니다.

Skills.

Language	SQL, Python, Java, Scala
Data Platform	Databricks, Delta Lake, Spark, Iceberg, Hadoop, Hive, Impala
Orchestration	Airflow, Oozie
Cloud	AWS (S3, SQS, DMS, Redshift, Aurora, Glue)
Infra · Deploy	Kubernetes (EKS), Terraform, ArgoCD, Jenkins
Monitoring	Prometheus, Grafana, Loki

Work Experience.

PFCT

데이터플랫폼팀 · 매니저
2026.01 - 현재

AI 기반 대출 리스크 관리 핀테크 기업, 크플 앱 운영

- Redshift → Databricks 메달리온 레이크하우스 전환 및 준실시간 CDC 파이프라인 구축 · 운영
- 데이터 분석 전용 시맨틱 레이어 구축, EKS 기반 Airflow 운영, AWS 인프라 Terraform 전환

디딤365

데이터솔루션팀 · 선임(대리)
2024.03 - 2025.12

금융기관 대상 빅데이터 플랫폼 구축 기업

- Spark · Iceberg 기반 금융권 대용량 배치 데이터 플랫폼 설계 · 개발, Hadoop 플랫폼 성능 최적화

디세이코리아

개발팀 · 사원(연구원)
2022.04 - 2023.08

AI 솔루션 전문기업, 이커머스 플랫폼 구축 사업

- 국내 · 베트남 이커머스 물류 플랫폼 API 개발, 상품 조회 **300ms → 90ms 미만** 단축, 쿠폰 동시 발급 제어

Projects.

PFCT

2026.02 - 현재

Redshift → Databricks 메달리온 레이크하우스 전환

- Redshift 기반 **약 20TB · 1,600개 테이블**을 Delta Lake 레이크하우스로 이관
- DMS CDC 기반 Bronze 준실시간 적재 구축, End-to-End Latency **p99 30초 이내** 달성
- DLT를 단일 Fan-out Job으로 재설계하고 Merge 병목 제거, **비용 39% 절감 · Merge 시간 73% 단축**
- DQ 검증 자동화로 누락 31만 행 · 순서 오류 15만 행 탐지 · 복구, **최종 누락 0건**
- 메달리온 계층별 S3 버킷 · Unity Catalog 구조와 권한 · 라이프사이클 정책 설계

PFCT
2026.03 - 2026.11

데이터 분석 전용 온톨로지 · 시맨틱 레이어 구축

- 의미가 겹치는 원천 테이블과 중복 컬럼을 전수 분석해, 기준 테이블을 하나로 정한 분석용 Gold 테이블 설계 · 구축
- 흩어진 데이터 정의를 시맨틱 레이어(OWL)로 표준화하고, 항상 같은 SQL로 실행되는 단일 지표 정의 체계 구축
- 기존 사내 온톨로지 대비 정답지 기준 **정답률 17% → 98%**, 동일 질문 응답 **일관성 30% → 98%** 달성
- LLM은 질의 의도만 추출하고 코드가 SQL을 생성하는 구조로 바꿔, **응답 시간 91% · LLM 토큰 사용량 87% 절감**

디딤365
2025.04 - 2025.08

Hadoop Ecosystem 기반 플랫폼 성능 최적화 및 고도화

- Java · HiveQL 기반 파기 시스템을 Scala · Spark 기반으로 전환, 데이터 범위 · 파티션 단위로 실행 구조 세분화
- 약 1,100개 파기 작업을 병렬 제출해 **CPU 코어 사용률 20~30% → 80%**, **처리 시간 70% 이상 단축**
- 반복되던 4억 행 백업 테이블 Join과 수작업 2차 집계를 선집계로 대체해, 전체 워크플로우 시간 **80% 단축**
- Hive 통계 누락으로 Sort-Merge Join되던 기준 테이블을 Broadcast로 바로잡아 같은 자원에서 처리량 **20% 향상**
- 배치 스케줄러의 힙 · TCP Connection 누수를 Heap Dump · 소켓 분석으로 제거해 월 장애 시간 **90% 이상 감소**, 가용성 **99.9%** 충족

디딤365
2024.07 - 2025.03

Spark · Iceberg 기반 대규모 데이터 파이프라인 플랫폼 설계 · 개발

- Spark · Iceberg 기반 플랫폼 아키텍처 설계 · 구현, 기존 Hadoop ETL 대비 **처리 시간 40% 단축**, S3 · Glue 등 HDFS 비종속 구조 확보
- 모듈 H/A · Failover 구현으로 장애 자동 복구율 **95% 이상** 달성
- Iceberg Snapshot 만료 · Orphan File 정리 자동화로 스토리지 사용량 **30% 이상 절감**
- DB Lock 기반 자원 제어 모듈로 일 평균 **800개 이상 배치 작업 · 25억 건** 데이터 안정 처리

Open Source.

오픈소스 한국 커뮤니티
멘토(운영진)
2025.05 - 현재

- 멘티 **500명 이상** 대상 오픈소스 기여 멘토링 진행
- Apache Iceberg, Paimon, Gravitino 등 **5개 프로젝트에 PR 20건 이상 merge**

Contributions

Apache Iceberg

- Delete 검사를 구간 단위 순회로 바꿔 검사 CPU 최대 **9배 감소** (#18027)
- Delete 파일 로드 실패 시 읽기 작업이 멈추던 장애 수정 (#3435)
- Delete 행 선택 방식 개선으로 읽기 성능 최대 **48% 향상** (#3454)

Apache Paimon

- 불필요한 Sort Merge를 생략해 읽기 시간 약 **62% 단축** (#1164)
- Merge 중 값 복사를 없애 메모리 할당 **19.6%** · 읽기 시간 **13% 감소** (#1338)

Education.

2024.03 - 2026.08 **한국방송통신대학교** · 컴퓨터과학과

2015.03 - 2019.02 **강남대학교** · 국어국문학과