# 전대홍

## Data Engineer

daehong770@gmail.com | GitHub | Blog | LinkedIn

## Introduce

데이터 플랫폼의 설계부터 개발, 성능 최적화까지 경험해 온 데이터 엔지니어 전대홍입니다.

금융권에서 Hadoop · Spark · Iceberg 기반 배치 데이터 플랫폼을 설계 · 개발하며 **일 평균 25억 건, 수백TB 규모**의 데이터를 처리한 경험이 있습니다. 핀테크에서는 Redshift 기반 DW를 Databricks 레이크하우스로 전환해 **약 1,600개 테이블 · 수십TB**의 데이터를 **적재 누락 0건**으로 이관하고, 준실시간 파이프라인을 구축한 경험이 있습니다.

## Skills

| | |
|---|---|
| Language | SQL, Python, Java, Scala |
| Data Platform | Databricks, Delta Lake, Spark, Iceberg, Hadoop, Hive, Impala |
| Orchestration | Airflow, Oozie |
| Cloud | AWS (S3, SQS, DMS, Redshift, Aurora, Glue) |
| Infra · Deploy | Kubernetes (EKS), Terraform, ArgoCD, Jenkins |
| Monitoring | Prometheus, Grafana, Loki |

## Work Experience

### PFCT

AI 기반 대출 리스크 관리 핀테크 기업, 크플 앱 운영

**데이터플랫폼팀**
매니저
2026.01 - 현재

#### Redshift → Databricks 메달리온 레이크하우스 전환

- **수십TB · 1,600개 테이블** 이관 및 DMS CDC 기반 Bronze 적재 구축, E2E Latency **p99 30초 이내 달성**
- DLT → Fan-out Job 재설계로 Merge 병목을 개선하여, **Compute 비용 39% · Merge 시간 73% 단축**
- DQ 검증 자동화로 적재 누락 31만 건 · 순서 오류 15만 건을 찾아 복구, **최종 누락 0건 달성**
- 메달리온 계층별 S3 버킷 · Unity Catalog 구조와 권한 · 라이프사이클 정책 설계

#### 데이터 분석 전용 시맨틱 레이어 구축

- Redshift에 파편화된 **약 250개 대출 도메인 테이블**을 업무 흐름 기준으로 통합해 Data Mart 구축
- 사내 온톨로지 대비 **정답률 17% → 98%**, **일관성 30% → 98%**, **응답 시간 91% · LLM 토큰 87% 절감**

#### AI 기반 인프라 운영 체계 구축

- 콘솔로 관리하던 AWS 리소스 **약 1,200개를 Terraform IaC로 전환**, 상태 일치 검증으로 **무중단 이관**
- 하네스 엔지니어링으로 팀 공용 AI · IaC Workspace 구축 및 운영
- VPC 내부 CodeBuild Runner로 **망분리 환경의 Databricks Workspace까지 IaC로 관리**

#### 데이터 플랫폼 운영 · 업무 자동화

- EKS 기반 Airflow 운영 및 신규 데이터 파이프라인 구축, DMS · Zero-ETL 운영 및 이슈 대응
- Grafana · Prometheus · Loki로 데이터 플랫폼 모니터링 · 이슈 분석 · 장애 대응
- 인스턴스를 Graviton(ARM)으로 전환하며 컨테이너 이미지를 amd64 · arm64 멀티 아키텍처로 표준화
- DQ 검증 파이프라인과 LLM 기반 코드 리뷰 자동화로 데이터 품질 검증 · 반복 업무 효율화

### 디딤365

금융기관 대상 빅데이터 플랫폼 구축 기업

**데이터솔루션팀**
선임(대리)
2024.03 - 2025.12

**Hadoop 에코시스템 기반 개인신용정보 파기 시스템 성능 최적화**

- 약 1,100개 파기 Job 제출 병렬화로 **CPU 코어 사용률 20~30% → 80%, 처리 시간 70% 단축**
- 반복되던 4억 행 백업 테이블 Join과 수작업 집계를 선집계로 바꿔 **전체 워크플로우 시간 80% 단축**
- Hive 통계 누락으로 잘못 선택되던 Join을 Broadcast Join으로 교정해 **처리량 20% 향상**
- 셔플 파티션별로 쌓이던 Small File을 coalesce로 병합해 NameNode 메타데이터 · 조회 부하 감소
- Heap Dump로 배치 스케줄러의 JVM Heap · TCP 누수를 찾아 수정해 **월 장애 시간 90% 감소**

**Spark · Iceberg 기반 신규 배치 데이터 플랫폼 설계 · 개발**

- Spark · Iceberg 아키텍처 기반 설계 및 구축으로 기존 Hadoop 플랫폼 대비 **처리 시간 40% 단축**
- Module H/A · Failover 체계 구현으로 장애 시 대기 노드 자동 전환, **장애 자동 복구율 95% 이상 달성**
- Iceberg Snapshot · Orphan File 정리 자동화로 **스토리지 30% 절감**
- Spark Standalone에 DB Lock 기반 자원 스케줄러를 구축해 Core · Memory · SLA Queue별 제출을 제어하고 Driver 데드락 방지, **일 평균 800개 이상 배치 · 25억 건** 처리

### 디세이코리아

AI 반도체 솔루션 전문기업, 이커머스 플랫폼 구축 사업 병행

**개발팀**
사원(연구원)
2022.04 - 2023.08

**E-commerce B2C 플랫폼 설계 · 개발**

- ngram Full Text Index · 쿼리 튜닝으로 상품 조회 **300ms → 90ms 미만** 단축
- DB Lock · 트랜잭션 재설계로 동시 발급 시 **이벤트 쿠폰 중복 · 초과 발급 방지**

**데이터 처리 성능 최적화**

- 대용량 처리 도구로 **파일당 수십 GB CSV를 Chunk 단위로 분할 · 병렬 처리**, Wafer LOT ID 기준 분류

---

## Open Source

**오픈소스 한국 커뮤니티** / 멘토(운영진) 2025.05 - 현재

- 기수별 오픈소스 기여 멘토링을 운영하며 **누적 500명 이상** 멘티 지도
- Apache Iceberg, Paimon, Gravitino 등 **5개 프로젝트에 PR 20건 이상 merge**

**Apache Iceberg** / Contributor

- Spark 벡터화 읽기에서 행마다 하던 Position Delete Index 조회를 범위 단위 순회로 바꿔 CPU 사용량 최대 **9.3배 감소** (#18027)
- Position Delete 로딩 실패 시 Loading 상태가 풀리지 않던 무한 대기 문제 수정, 실패 감지 · 재시도 로직 구현 (#3435)
- Delete Vector의 연속 삭제 구간으로 Row Selection을 만들어 Row Group 탐색을 줄이고 읽기 시간 최대 **48% 단축** (#3454)

**Apache Paimon** / Contributor

- 정렬 구간이 하나뿐일 때 불필요한 Sort Merge를 생략하고 중복 키 검증 경로를 추가해 읽기 시간 **102ms → 18ms** 단축 (#1164)
- 집계 과정에서 승자 레코드를 복사하지 않고 참조로 처리해 메모리 할당 **19.6%** · 읽기 시간 **13% 감소** (#1338)

---

## Education

**한국방송통신대학교** / 컴퓨터과학과 2024.03 - 2026.08

**강남대학교** / 국어국문학과 2015.03 - 2019.02